


SUMÁRIO

SUMÁRIO.....	1
1. Introdução e Contextualização do Problema.....	2
1.1. O Tennessee Eastman Process como Benchmark Industrial.....	2
1.2. Desafios da Planta Química.....	2
1.3. A Visão TEP-Sentinel.....	3
2. Arquitetura Sistêmica e Fluxo de Informação.....	3
2.1. O Orquestrador Central.....	3
2.2. O Simulador Neural (Surrogate Model).....	4
2.3. Metodologia "Sense-Think-Act-Explain".....	4
3. Engenharia de Dados e Pipeline de Processamento.....	5
3.1. Estratégia de Ingestão com Parquet.....	5
3.2. Prevenção de Data Leakage.....	5
3.3. Janelamento Temporal (Sliding Windows).....	6
4. Monitoramento Inteligente e Diagnóstico de Falhas (FDD).....	6
4.1. Detecção Não-Supervisionada com Autoencoders.....	6
4.2. Classificação de Causa Raiz via CNN-LSTM.....	7
4.3. Métricas de Performance.....	7
5. Controle Autônomo via Reinforcement Learning.....	8
5.1. O Agente PPO (Proximal Policy Optimization).....	8
5.2. Camada de Segurança (Safety Layer).....	9
5.3. Otimização e Inferência em Tempo Real.....	9
6. IA Explicável (RAG) e Interface com o Operador.....	9
6.1. Módulo RAG com Gemini 2.0.....	10
6.2. Dashboard Streamlit.....	10
6.3. Apoio à Decisão (Copiloto).....	11
7. Viabilidade Industrial e Conclusão.....	11
7.1. Convergência OT/IT.....	11
7.2. O Tripé da IA Industrial.....	11
7.3. Impacto Econômico.....	11

1. Introdução e Contextualização do Problema

O Tennessee Eastman Process (TEP) é um modelo matemático de simulação de uma planta química real, criado e disponibilizado pela empresa Eastman Chemical Company em 1993. Desde sua publicação por Downs & Vogel, ele se consolidou como o "Padrão Ouro" (Benchmark) mundial para o desenvolvimento e teste de novas tecnologias em controle de processos, como PID e MPC, detecção e diagnóstico de falhas (FDD) e segurança operacional. Antes da introdução do TEP, as pesquisas acadêmicas baseavam-se em modelos excessivamente simplificados, como tanques de nível ou pequenos fornos, que não capturavam a complexidade sistêmica encontrada em instalações industriais de grande porte.



1.1. O Tennessee Eastman Process como Benchmark Industrial

A importância do TEP reside na sua capacidade de trazer a complexidade do mundo real para o ambiente computacional, permitindo a validação de algoritmos em um cenário rigoroso. Ele é amplamente utilizado para avaliar a eficácia de sistemas de monitoramento e controle devido à sua estrutura multivariável, onde o ajuste de uma única variável, como a válvula de um separador, pode alterar drasticamente a pressão de um reator em estágios anteriores do processo. Essa característica de "tudo afeta tudo" exige que qualquer solução de controle seja

capaz de lidar com acoplamentos fortes e interdependências complexas entre os componentes da planta.

1.2. Desafios da Planta Química

A operação da "fábrica virtual" do TEP impõe desafios técnicos severos, sendo caracterizada por um comportamento altamente não-linear, onde as reações químicas sofrem mudanças bruscas em função da temperatura e pressão. Um dos riscos mais críticos é a instabilidade em malha aberta (Open-Loop Unstable): caso os controladores sejam desativados, o reator pode atingir um estado de falha catastrófica — uma "explosão matemática" — em menos de uma hora. Além disso, o processo lida com reações exotérmicas que geram calor intenso, exigindo resfriamento constante para evitar o superaquecimento e garantir a integridade operacional do sistema.


1.3. A Visão TEP-Sentinel

O projeto TEP-Sentinel foi concebido não apenas como um controlador convencional, mas como uma camada de inteligência avançada posicionada acima do controle básico do processo. Nossa missão consiste em utilizar a Inteligência Artificial para atuar de forma proativa: detectar desvios sutis antes que os alarmes convencionais sejam acionados, diagnosticar a causa raiz entre as diversas falhas programadas na simulação e agir automaticamente, via Aprendizado por Reforço (RL), para estabilizar a planta. Em essência, o TEP atua como nosso "simulador de voo"; o sucesso da nossa IA em pilotar esta planta química instável e repleta de anomalias valida sua capacidade de gerir processos industriais reais com segurança e eficiência.

2. Arquitetura Sistêmica e Fluxo de Informação

Neste capítulo, detalhamos a engenharia de software e a integração dos modelos de IA que compõem o TEP-Sentinel. O sistema foi projetado para operar de

forma modular, onde cada componente desempenha um papel específico na manutenção da estabilidade e na aplicabilidade do processo industrial.



Módulos & Componentes		
AMBIENTE DIGITAL Simulação TEP Digital Twin da planta química Tennessee Eastman. Utiliza um modelo neural (LSTM) treinado em dados históricos para simular a física do processo em tempo real. <code>envs/tep_env.py</code>	DETECÇÃO (FDD) Monitoramento Inteligente Rede neural Autoencoder que aprende o comportamento normal da planta. Detecta anomalias sutis (desvios de MSE) e aciona o classificador CNN-LSTM para identificar a causa raiz. <code>models/tep_autoencoder.keras</code>	CONTROLE AUTÔNOMO Agente PPO Piloto automático treinado via Reinforcement Learning. Atua sobre 11 válvulas de controle para estabilizar o processo e mitigar falhas, garantindo a segurança operacional. <code>models/PPO/best_model1.zip</code>
IA GENERATIVA Explainable AI (RAG) Sistema RAG que traduz códigos de erro em relatórios técnicos. Consulta manuais no ChromaDB e usa o Google Gemini para orientar o operador com ações corretivas. <code>rag_agent.py</code>	FRONTEND Dashboard Streamlit Interface de comando e controle. Permite visualizar KPIs em tempo real, injetar falhas para testes e receber diagnósticos da IA. <code>dashboard.py</code>	BACKEND Orquestrador Núcleo do sistema (<code>tep_system.py</code>) que integra o ciclo de sensoriamento, detecção, decisão e explicação (Sense-Think-Act-Explain). <code>tep_system.py</code>

2.1. O Orquestrador Central

O orquestrador atua como o "Cérebro Central" do sistema, sendo responsável por gerenciar o ciclo fechado (Closed-Loop) de operação. Sua função é garantir a sincronia entre as diferentes camadas da solução:

- Gerenciamento de Dados: Mantém um buffer de dados rolante (Rolling Window) das últimas 100 amostras para alimentar os modelos temporais.
- Integração de Módulos: Conecta o ambiente de simulação aos módulos de detecção (FDD), decisão (RL) e explicação (RAG).
- Estabilidade do Sistema: Garante que os modelos permanecem carregados em memória para uma resposta em tempo real, eliminando latências de processamento.

2.2. O Simulador Neural (Surrogate Model)

Devido à complexidade e às restrições de acesso ao simulador Fortran original do TEP, implementamos um "Gêmeo Digital" baseado em um Surrogate Model (Modelo Substituto).

- Arquitetura LSTM: Utilizamos uma rede de Long Short-Term Memory (LSTM) treinada para prever o próximo estado do processo $S(t+1)$ com base no estado atual e nas ações de controle aplicadas.
- Imitação da Física: O modelo aprendeu a dinâmica básica do TEP, incluindo as correlações críticas entre pressão, nível e temperatura, apresentando um erro quadrático médio (MSE) de treinamento de ~ 19.2 .
- Infraestrutura de Treino: Este simulador neural forneceu o ambiente seguro e acelerado necessário para treinar o agente de Reinforcement Learning sem o risco de danos físicos ao sistema.

2.3. Metodologia "Sense-Think-Act-Explain"

A arquitetura do TEP-Sentinel segue a filosofia Sense-Think-Act-Explain, integrando três pilares da IA moderna em uma plataforma unificada para elevar a gestão industrial:

- Sense (Sensoriamento): O ambiente (TEPEnv) captura as 52 variáveis monitoradas no painel de controle.
- Think (Monitoramento FDD): O módulo de detecção de falhas analisa os dados em busca de anomalias e identifica a causa raiz (Deep Learning).
- Act (Controle RL): O agente toma decisões autônomas para estabilizar a planta e retornar as variáveis aos seus setpoints (Reinforcement Learning).
- Explain (Explicação RAG): Caso uma falha seja detectada, o sistema consulta manuais técnicos e gera um relatório explicativo em linguagem natural para o operador (Generative AI).

3. Engenharia de Dados e Pipeline de Processamento

Esta seção detalha o rigor estatístico e técnico aplicado na preparação dos dados, garantindo que o TEP-Sentinel opere sobre uma base sólida e livre de vieses que poderiam comprometer a detecção de anomalias em um ambiente industrial real.


3.1. Estratégia de Ingestão com Parquet

Os dados originais da simulação do Tennessee Eastman Process são distribuídos em arquivos no formato .RData, nativos da linguagem R. Para integrar esses dados ao nosso pipeline de Deep Learning em Python, optamos pela conversão para o formato Parquet. Esta escolha foi estratégica, pois o Parquet é um formato de armazenamento colunar que oferece uma compressão de dados superior; enquanto um arquivo CSV equivalente poderia ultrapassar 2GB, o Parquet mantém os dados em centenas de megabytes. Além da eficiência de espaço, o formato preserva a tipagem dos dados (como float64 e int) e permite uma velocidade de leitura ordens de grandeza superior à do CSV dentro do ambiente Pandas. A implementação utilizou as bibliotecas pyreadr para a leitura inicial e pyarrow como motor de escrita.

3.2. Prevenção de Data Leakage

Um dos maiores desafios em modelos de detecção de falhas é evitar o "vazamento" de informações futuras ou anômalas para o treinamento do modelo.

Para mitigar esse risco, utilizamos o StandardScaler para normalizar os dados (ajustando a média para 0 e o desvio padrão para 1). O ponto crítico desta etapa é que o escalonador foi treinado exclusivamente nos dados do conjunto FaultFree Training (Livre de Falhas). Ao agir dessa forma, garantimos que os modelos de IA aprendam a estatística pura da operação normal, sem qualquer conhecimento prévio sobre o comportamento das falhas ou do conjunto de teste, o que é essencial para uma avaliação justa da capacidade de detecção. O estado final desse escalonador foi persistido no arquivo `tep_scaler.pkl` para uso em tempo real no dashboard.



3.3. Janelamento Temporal (Sliding Windows)

Dados industriais não são estáticos; eles possuem inércia térmica e hidráulica, o que significa que uma amostra isolada no tempo t não contém contexto suficiente para um diagnóstico preciso. Implementamos a estratégia de janelas deslizantes para capturar a dinâmica temporal do processo. Cada entrada para as

redes neurais consiste em uma janela de $T = 100$ amostras consecutivas, o que representa aproximadamente 3 minutos de histórico operacional.

Para o conjunto de treinamento, utilizamos um passo (stride) de 10 amostras, gerando sobreposição entre as janelas como uma forma de Data Augmentation para aumentar a robustez do modelo. Já para o conjunto de teste, utilizamos um stride de 100 (sem sobreposição), garantindo uma avaliação técnica rigorosa e economia de memória. O resultado final desse pipeline são tensores comprimidos em arquivos .npz, totalizando mais de 600 mil amostras sequenciais prontas para alimentar as arquiteturas LSTM e Autoencoders.

4. Monitoramento Inteligente e Diagnóstico de Falhas (FDD)

O "Cérebro" do sistema TEP-Sentinel é composto por uma estrutura redundante de detecção e diagnóstico, atuando como uma camada de proteção entre o processo e o operador. Esta fase implementa uma lógica de triagem onde dois modelos complementares trabalham em conjunto: o Autoencoder, que atua como um "semáforo" de segurança, e o CNN-LSTM, que assume o papel de "médico" para diagnosticar a patologia industrial específica.

4.1. Detecção Não-Supervisionada com Autoencoders


A primeira linha de defesa é o Detector de Anomalias, uma rede neural do tipo Autoencoder (Encoder-Decoder) treinada sob o paradigma de aprendizado não-supervisionado utilizando exclusivamente dados de operação normal.


- **Lógica de Reconstrução:** O modelo tenta reconstruir a janela de entrada; se o processo está em estado normal, o erro de reconstrução é baixo.
- **Threshold Dinâmico:** Definimos o limiar de alerta no percentil 99% do Erro Quadrático Médio (MSE) do treino.
- **Identificação de Desconhecidos:** Se o MSE ultrapassa este limite (ajustado para 30.7 após calibração), o sistema marca o estado como *FALHA*, sendo capaz de detectar até mesmo anomalias nunca antes vistas pelo modelo.

4.2. Classificação de Causa Raiz via CNN-LSTM

Uma vez que o Autoencoder sinaliza uma anormalidade, o Diagnosticador de Falhas entra em ação para identificar a causa raiz. Este modelo utiliza uma arquitetura híbrida avançada: a CNN extrai características espaciais e correlações entre as 52 variáveis, enquanto a LSTM interpreta a evolução temporal do desvio.

- Mapeamento de Falhas: O classificador foi treinado para distinguir entre as 20 falhas programadas (IDV 1 a 20).
- Análise de Desvios: O modelo analisa variáveis críticas como a Pressão do Reator (XMEAS 7) e a Temperatura do Reator (XMEAS 9), que são altamente correlacionadas e servem como "assinaturas" para diversos problemas térmicos e de pressão.
- Exemplo Prático: Na Falha 1 (Alteração na razão A/C), o modelo identifica padrões específicos como o aumento drástico na abertura da válvula de alimentação A (XMV 3) e a subida na pressão do reator.





4.3. Métricas de Performance

A robustez do sistema FDD foi validada estatisticamente para garantir confiabilidade na sala de controle e evitar a "fadiga de alarme"

Métrica	Valor Obtido	Impacto Operacional
FAR (False Alarm Rate)	0.69%	Redução drástica de alarmes falsos, garantindo que o operador confie no sistema.
Acurácia Global	85.55%	Alta confiabilidade na distinção entre 21 classes diferentes (Normal + 20 Falhas).
Precisão Média	92%	O sistema é extremamente preciso quando aponta uma causa específica.

TPR (True Positive Rate)	88.89%	Alta taxa de sucesso na detecção da Falha 1, capturando a maioria dos desvios críticos.
--------------------------	--------	---

O sistema demonstra uma performance superior em classes críticas, como a Falha 5 (Temperatura), onde atinge 100% de precisão, tornando-se uma ferramenta indispensável para a segurança do reator.

5. Controle Autônomo via Reinforcement Learning

Nesta fase, implementamos a infraestrutura para o Controle Autônomo da planta, atuando como um "Piloto Automático" inteligente capaz de tomar decisões em frações de segundo para manter a estabilidade operacional. Diferente dos controladores tradicionais que dependem de regras fixas, o sistema de Aprendizado por Reforço (RL) aprende a estratégia ideal através da interação contínua com o ambiente simulado, buscando minimizar desvios e mitigar falhas de forma proativa.


5.1. O Agente PPO (Proximal Policy Optimization)

O "motor" por trás da nossa estratégia de controle é o algoritmo Proximal Policy Optimization (PPO), selecionado por sua robustez e eficiência em lidar com espaços de ação contínuos e ambientes complexos. O agente foi treinado utilizando a biblioteca `stable-baselines3` para atuar diretamente sobre as 11 variáveis manipuladas (XMV), que representam as aberturas das válvulas de alimentação, reciclo e purga da planta. O objetivo central do PPO é manter as variáveis de medição (XMEAS) o mais próximo possível de seus setpoints ideais (valor zero após a normalização), garantindo que a produção de produtos vendáveis (G e H) ocorra de forma estável mesmo sob perturbações externas.

5.2. Camada de Segurança (Safety Layer)

Um dos maiores desafios da aplicação de IA em processos industriais críticos é garantir que o agente não tome ações catastróficas durante o processo de aprendizado. Para resolver isso, implementamos uma Camada de Segurança

(Safety Layer) hard-coded integrada diretamente ao ambiente envs/tep_env.py. Este mecanismo monitora continuamente o estado da planta e aplica penalidades severas ao agente caso ele sugira ações que levem a desvios críticos, definidos como variações superiores a 10σ (dez desvios padrão) em relação ao estado estável. Essa barreira física impede o "runaway" do reator (explosão matemática) e garante que, mesmo em busca de eficiência, o sistema nunca viole as restrições físicas de segurança.



5.3. Otimização e Inferência em Tempo Real

A eficácia de um controlador industrial depende da sua capacidade de resposta. Para viabilizar o treinamento e a operação em tempo real, utilizamos um

Surrogate Model (LSTM) que emula a física do TEP com alta fidelidade. Implementamos a compilação JIT (Just-In-Time) através do decorador `@tf.function` no ambiente de simulação, o que resultou em uma aceleração de 50x na velocidade de processamento, elevando a taxa de inferência de ~2 passos por segundo para aproximadamente 100 passos por segundo. Esse ganho de performance permite que o sistema processe as janelas temporais de dados, execute os modelos de diagnóstico e tome ações de controle de forma quase instantânea, um requisito crítico para gerenciar as rápidas dinâmicas de pressão e temperatura do reator.

6. IA Explicável (RAG) e Interface com o Operador

Nesta seção, descrevemos como o TEP-Sentinel traduz a complexidade dos dados industriais em informações acionáveis para o ser humano, utilizando tecnologias de IA generativa e interfaces interativas.

6.1. Módulo RAG com Gemini 2.0



O sistema utiliza a técnica de RAG (Retrieval-Augmented Generation) para fornecer diagnósticos explicáveis. O processo inicia-se quando o módulo de detecção identifica uma falha e envia o código correspondente (ex: IDV 1) para o Agente RAG.

- **Busca Semântica:** O agente realiza uma consulta em um banco de dados vetorial (ChromaDB), que contém manuais técnicos e documentação da planta indexados.
- **Processamento de Linguagem Natural:** Utilizando o modelo Google Gemini 2.0 Flash, o sistema cruza os dados recuperados com o contexto da falha para gerar um relatório técnico em linguagem natural.
- **Acurácia:** Esta abordagem elimina a necessidade de o operador memorizar códigos de erro, transformando um alerta matemático em uma explicação clara sobre a causa raiz.

6.2. Dashboard Streamlit

A interface de comando do projeto foi desenvolvida em Streamlit (dashboard.py), priorizando a visualização em tempo real e a facilidade de uso.

- Controle da Simulação: O operador pode iniciar, parar ou resetar a simulação diretamente pelo painel.
- Visualização de KPIs: O dashboard exibe gráficos dinâmicos de variáveis críticas, como a Pressão do Reator e o Nível, além do score de anomalia (MSE) calculado pelo Autoencoder.
- Injeção de Falhas: Para fins de teste e validação de robustez, a interface permite injetar anomalias específicas e observar a resposta imediata dos sistemas de detecção e controle.



6.3. Apoio à Decisão (Copiloto)

O TEP-Sentinel atua como um "Engenheiro Sênior Virtual", auxiliando na democratização do conhecimento técnico dentro da planta.

- Redução do MTTR: Ao sugerir ações corretivas imediatas baseadas em manuais (ex: "verificar válvula X", "reduzir vazão Y"), o sistema reduz drasticamente o tempo médio de reparo (Mean Time to Repair).
- Suporte em Emergências: Em cenários de alta pressão, a IA fornece suporte à decisão menos dependente da experiência individual do operador, consultando terabytes de manuais em segundos.

EXEMPLO A SEGUIR:

Fault Analysis and Recommendations

1. Fault Identification

Based on the Alert Code IDV(6), the technical name of the fault is Falha Temp. (Failure related to Temperature). This is inferred from the "Destques por Classe" table in the Diagnosticador de Falhas section, where Classe 5 corresponds to "Falha Temp."

2. Root Cause Explanation

While the provided context doesn't specify which temperature is failing, the high MSE error (2.2333) indicates a significant deviation from normal operating conditions. Given the strong correlation between Reactor Pressure and Temperature, a temperature fault could be related to issues within the reactor itself, or in systems affecting the reactor temperature, such as feed preheating or cooling systems.

3. Recommended Actions for the Operator

Given the "Falha Temp." alert and the high MSE error, the operator should take the following actions:

Immediate Actions:

Verify Reactor Temperature (XMEAS 7): Confirm the reactor temperature reading and compare it to the setpoint. A significant deviation warrants immediate investigation.

Check Reactor Pressure (XMEAS 7): As temperature and pressure are highly correlated, verify the reactor pressure reading. A simultaneous deviation in pressure and temperature strongly suggests a reactor-related issue.

Acknowledge and Log the Alarm: Ensure the alarm is acknowledged in the control system and a detailed log entry is created, documenting the time, alarm details, and initial observations.

Investigative Actions:

Examine Feed Temperatures: Check the temperatures of the incoming feed streams (A, C, D, E) to ensure they are within the expected ranges. A deviation in feed temperature can directly impact the reactor temperature.

Inspect Cooling System: Verify the functionality of the reactor cooling system. Check coolant flow rates, coolant temperature, and the status of any associated pumps or valves.

Review Reactor Heating System: If the reactor uses a heating system (e.g., steam tracing), check the steam supply pressure and flow rate.

Analyze Recent Process Trends: Review recent trends of relevant process variables (temperatures, pressures, flow rates) to identify any patterns or anomalies that may have preceded the alarm.

Check for Fouling: If the temperature deviation is gradual, consider the possibility of fouling on heat transfer surfaces within the reactor or associated heat exchangers.

Valve Checks:

Cooling Water Valve: Verify the position and operation of the cooling water valve controlling the reactor temperature.

Steam Valve (if applicable): If steam is used for heating, check the steam valve position and ensure it is responding correctly.

Setpoint Adjustments:

Avoid immediate setpoint adjustments: Do not attempt to correct the temperature by drastically changing setpoints without first understanding the root cause. This could mask the underlying problem or potentially exacerbate the situation. Only make small, controlled adjustments if necessary, and carefully monitor the response.

Important Considerations:

Safety First: Prioritize safety in all actions. If the temperature deviation is significant and poses a safety risk, initiate emergency shutdown procedures as necessary.

Consult with Experts: If the root cause is not immediately apparent, consult with process engineers or other experts for further guidance.

Document Everything: Maintain a detailed record of all actions taken, observations made, and any changes to process parameters. This documentation will be invaluable for future troubleshooting and analysis.

7. Viabilidade Industrial e Conclusão

O encerramento deste relatório foca na transição do projeto de um ambiente de simulação para uma aplicação real em refinarias ou plantas químicas.

7.1. Convergência OT/IT

Para a implementação industrial (Indústria 4.0), a arquitetura do TEP-Sentinel deve evoluir para suportar a convergência entre as tecnologias de operação (OT) e informação (IT).

- Camada Física (OT): Sensores de campo conectados a controladores lógicos programáveis (PLCs) via protocolos como Modbus ou OPC-UA.

- Edge Computing: Gateways industriais instalados localmente devem rodar o módulo de detecção (Autoencoder) para garantir latência zero na detecção de anomalias críticas, sem dependência total da nuvem.

7.2. O Tripé da IA Industrial

O projeto demonstra com sucesso a eficácia da orquestração de três pilares fundamentais da IA moderna no setor manufatureiro:

- Monitoramento Não-Supervisionado: Autoencoders que detectam o desconhecido.
- Controle Inteligente: Reinforcement Learning (RL) para otimização além da capacidade humana.
- Explicabilidade: IA Generativa (RAG) que traduz matemática complexa para o operador.

7.3. Impacto Econômico

A implementação deste ecossistema gera valor de negócio tangível ao transformar dados brutos em decisões estratégicas.

- Eficiência Operacional: Redução do downtime e do desperdício de matéria-prima através da detecção precoce e controle adaptativo.
- Gestão de Conhecimento: O sistema mitiga a "fuga de cérebros" ao digitalizar e tornar consultável o conhecimento tácito de operadores experientes.

O TEP-Sentinel prova que a verdadeira revolução industrial não reside em ferramentas isoladas, mas na colaboração entre humano e IA, onde a máquina cuida da complexidade operacional e o ser humano foca na estratégia (Indústria 5.0).

